



CIENCIA DE DATOS EN REÑAS DE VINOS

Violeta Francescangeli
26/04/2026

Índice

Índice	pág. 1
Importancia y uso de la Ciencia de datos	pág. 2
Macrodatos: desafíos y oportunidades	pág. 5
Inteligencia artificial y aprendizaje automático	pág. 7
Limpieza, análisis y visualización de datos	pág. 11

Importancia y uso de la Ciencia de datos

¿De qué manera la ciencia de datos puede mejorar la comprensión de los factores que influyen en la calidad y características de los vinos, y cómo puede esta información ser utilizada por productores y comerciantes para tomar decisiones informadas?

En la actualidad los datos nos “invaden” La ciencia de datos hace uso de distintas tecnologías y herramientas para poder comprender los datos y descubrir información valiosa que esta oculta en las grandes cantidades de datos. Para lograrlo se deben seguir una serie de pasos.

1. El primer paso es la **recolección de datos** de diversas fuentes. En esta instancia es muy importante el contexto de origen. El contexto de origen refiere a los tipos de fuentes de las que provienen los datos, el momento y lugar en el que se crearon, si fueron ingresados por humanos, si eventos externos influyeron en ellos, quien los genero (si puede haber sesgos que afecten su calidad).

En el caso planteado los datos provienen de un sitio de reseñas de vinos llamado WineEnthusiast, donde podemos encontrar datos sobre sus precios, origen, descripción, etc. Dichos datos son proporcionados por expertos en vinos.

2. Luego viene la **limpieza y preparación** de los datos. El dataset debe ser estructurado para su posterior análisis, esto se logra mediante distintas técnicas como, la eliminación de duplicados, corrección de errores estructurales, relleno o eliminación de valores faltantes, en caso de rellenarlos se utilizan técnicas como media, mediana o moda o modelos predictivos para acercarse al valor ausente, también se realiza la validación de datos para asegurarse que se cumplan las reglas lógicas.

En el caso planteado lo primero a realizar es una estructuración de los datos en una tabla para poder visualizarlos y poder identificar que tipo de datos contiene. Luego detectar valores nulos o errores y hacer conversiones de tipos de datos.

3. Con los datos ya preparados se prosigue con el **análisis exploratorio**. En esta etapa se deben explorar y “conocer” los datos, se analiza

su estructura y distribución, y se detectan posibles anomalías, errores, patrones y relaciones entre variables que no se ven a simple vista.

Aquí podemos analizar las distintas variables como los precios, las regiones, hacer agrupaciones por países, agrupar según calificación o precio, analizar la relación entre precio y calidad (puntos), o región y precio, saber que cantidad y tipos de variedades hay, etc.

4. Luego de realizar el análisis exploratorio se debe elegir el **modelo** según el objetivo. Aquí debemos construir una representación matemática que se adecue con el objetivo, ya sea de predicción, clasificación o agrupación.

En esta instancia podemos realizar distintos modelos según el objetivo del cliente.

Por ejemplo, en el caso de los productores, podemos realizar modelos de regresión para poder predecir la puntuación estimada en función de las variables de región, precio y variedad. O utilizar clustering para agrupar los vinos según su variedad y sacar un promedio de su puntuación o precio y así realizar una mayor producción de una variedad determinada.

Para el área de comerciantes y distribuidores podríamos realizar una segmentación de mercado identificando que países ofrecen vinos con mejor relación precio-calidad o que variedad de uva tiene una puntuación promedio más alta. también mediante un modelo de regresión podríamos estimar el precio según la variedad y la región.

5. En esta instancia los datos deben **interpretarse y comunicarse**. Se hace una representación visual de los datos utilizando gráficos y dashboards en los cuales se comprenda de forma rápida y sencilla que se quiere decir, es como un "resumen" de lo que dicen los datos, mediante los insights podemos presentar conclusiones que surgen del análisis. Aquí también se lleva a cabo la documentación y el registro de cada paso del proyecto. Esta parte es importante ya que aporta transparencia y credibilidad al proceso.

Para esta etapa debemos realizar recomendaciones y presentar la información de forma intuitiva y comprensiva según el objetivo y a quien se dirige la información. Por ejemplo, un gráfico de dispersión que presente los países con mejor relación precio-calidad, o un grafico de barras que muestre que variedad tiene mayor cantidad de reseñas positivas.

6. El ultimo paso es la **iteración y mejora**, este es un proceso cíclico, ya que siempre surgen nuevos datos de los cuales podemos aprender y generar información nueva o mejorar el modelo creado anteriormente.

En este caso con la Ciencia de datos podemos realizar un análisis exhaustivo del gran volumen de datos y variables proporcionados en el dataset. Gracias al análisis y exploración de los datos los comerciantes y productores pueden tomar decisiones informadas, identificar oportunidades de negocios, predecir y comprender tendencias y comportamientos y resolver problemas complejos a través de técnicas avanzadas de análisis de datos. Este análisis puede orientarse según las necesidades específicas de cada actor, ya sean productores o comerciantes. Por ejemplo, los productores pueden tomar decisiones respecto a el proceso de elaboración y producción, aumentando la producción de productos con una buena relación precio-calidad o aumentando la producción de variedades con buenas reseñas. Otra posibilidad es analizar los países o regiones con mejores reseñas en caso de querer iniciar una producción en un área diferente.

En el caso de los comerciantes pueden utilizar la información obtenida para identificar los países que ofrecen mejor precio o identificar las variedades de vinos con mejor puntuación o bodegas con mejor relación precio-calidad. También pueden identificar que bodega tiene una puntuación promedio más alta para realizar acuerdos comerciales.

Macrodatos: desafíos y oportunidades

Dado el gran volumen de datos disponible en el set de datos de reseñas de vinos, ¿qué desafíos y oportunidades presentan los macrodatos para el análisis y la visualización de información relevante en la industria del vino?

Los macrodatos son también conocidos como "Big Data". Según IBM el termino big data es de gran importancia debido a "su capacidad para influenciar profundamente en el comercio de una economía integrada a escala global". Inspira nuevas formas de transformar procesos y empresas.

Las 3V del big data (volumen, variedad y velocidad) son las principales características que lo definen, pero el avance tecnológico a obligado a considera nuevos factores para caracterizar al big data por lo que a las 3V se le agregan otras 3V (veracidad, visualización y valor).

Los macrodatos sirven para extraer conocimiento útil a partir de grandes volúmenes de datos. Su valor esta dado por su capacidad para proporcionar información sobre qué está pasando realmente en tiempo real y con precisión, apoyando así la toma de decisiones basada en datos.

En el caso planteado los macrodatos son de gran utilidad ya que el dataset proporcionado contiene un gran volumen de reseñas de vinos con múltiples variables, lo que permite aplicar ciencia de datos, para obtener insights útiles, en este caso podríamos identificar tendencias como variedades más valoradas, países con mejor relación precio-calidad, con clustering podemos generar agrupaciones según estilo, calidad, región, puntuación o rango de precios. También pueden crearse dashboards interactivos, mapas de calor, entre otras estrategias de visualización para presentar la información e insights de forma clara y persuasiva.

Poder manejar y analizar los macrodatos es un desafío, ya que se requiere de soluciones, técnicas y de tecnologías complejas. Debido al gran volumen de datos (terabytes o pentabytes) es necesario una arquitectura robusta y escalable para el almacenamiento de información. Su procesamiento y seguridad son todo un desafío ya que debe procesarse una gran cantidad de información de forma rápida y segura, manteniendo la privacidad sobre todo si se tienen datos sensibles. Otro desafío es la integración de información de diferentes fuentes las cuales suelen tener distintos

formatos, por lo que deben poder transformarse a un único formato sin perder el significado y su utilidad. Se requieren de habilidades y conocimiento especializado en el tema para realizar un filtrado, corrección de errores y finalmente una interpretación de la información, ya que muchas veces para la detección errores, sesgos, como también saber que datos debemos considerar y cuales descartar es necesario un profesional con conocimiento específico en el área a tratar.

En cuanto al tema planteado, los desafíos son los antes mencionados. Principalmente es necesarios el uso de herramientas y técnicas para explorar el data set, ya que con más de 130000 reseñas hacerlo de forma manual es imposible. En calidad y limpieza el dataset contiene valores nulos por lo que deben estudiarse y tomar una decisión sobre si borrar esos registros o tratar de inferir su valor. La fuente de la que provienen los datos es una, pero el dataset se encuentra en texto plano porque es necesario estructurarlo para que sea más sencillos explorarlo y podamos identificar las variables proporcionadas. El dataset contiene distintos tipos de variables como, numéricas y texto por lo que deberán usarse distintas técnicas para cada tipo.

Otro de los desafíos es la visualización efectiva, con tanta información esta debe presentarse visualmente clara y resumida. también debemos requerir al asesoramiento de profesionales con conocimientos sobre el área vinícola para poder detectar si se presenta algún tipo de sesgo o error no detectable fácilmente en el dataset.

Para superar estos desafíos es necesario el conocimiento y uso de tecnologías y herramientas para el procesamiento de macrodatos. En el caso de las reseñas de vinos será necesario el uso de Python y bibliotecas de análisis de dato como pandas para poder manipular, limpiar y explorar los datos de forma eficiente. también se podría convertir el archivo para poder utilizarlo en una base de datos relacional como SQL y poder hacer consultas, filtrados y agrupamientos. deberíamos usar herramientas de procesamiento de lenguaje natural en caso de querer extraer información útil de la variable "description".

Mediante le uso de machine learning podríamos construir modelos predictivos para estimar puntuación o precios. también podríamos realizar segmentaciones automáticas.

Finalmente deberíamos usar herramientas de visualización de datos como PowerBI o Tableau para poder comunicar insights de forma clara, dinámica y resumida.

Inteligencia artificial y aprendizaje automático

Aunque este caso de estudio se centra en el análisis exploratorio y no en la predicción, ¿cómo podría la inteligencia artificial y el aprendizaje automático ser utilizados para desarrollar modelos predictivos que identifiquen variedades de vino basándose en descripciones textuales? ¿Qué beneficios y limitaciones podrían surgir de esta aplicación?

La inteligencia Artificial (IA) busca crear sistemas que imiten las capacidades humanas, como razonamiento, toma de decisiones y la interpretación del lenguaje natural. Es un conjunto de tecnologías y técnicas. El aprendizaje automático (machine learning) es una rama de la Inteligencia artificial que permite a las máquinas aprender a partir de datos. Permite hacer predicciones, descubrir patrones y aprender por sí mismos.

Para poder aplicar Inteligencia Artificial debemos seguir los pasos explicados anteriormente de recolección y preparación de los datos, luego hacemos la elección del modelo y entrenamos dicho modelo con los datos filtrados, hacemos una evaluación de resultados y si estos son consistentes o tienen una correlación lógica el modelo ya está entrenado y listo para hacer predicciones o tomar decisiones.

Una de las tareas que se podría llevar a cabo sería la de transformar descripciones escritas en información estructurada (la **variedad** de uva), lo que se enmarca como un problema de **clasificación supervisada**: se usan ejemplos etiquetados (reseñas con su variedad) para que el sistema aprenda a generalizar.

Los pasos seguir para poder llevar a cabo esta tarea deberían ser los siguientes:

Primero debemos seleccionar y filtrar las reseñas con descripción y variedad válidas, luego debemos normalizar el texto para reducir ruido (minúsculas, eliminación de caracteres irrelevantes y palabras vacías); a continuación se transforma el texto en características que el modelo pueda usar (por ejemplo, representaciones basadas en palabras); después se entrena un modelo de clasificación con ejemplos etiquetados; y finalmente se evalúa su desempeño y se revisan errores representativos para mejorar el proceso.

Hay distintos tipos de aprendizaje automático:

- **Aprendizaje supervisado**: el agente aprende a partir de un conjunto de datos etiquetados (ejemplos) los cuales en cada entrada tienen una salida conocida, el objetivo del algoritmo que pueda generalizar los ejemplos para realizar predicciones o clasificaciones precisas cuando se le presenten

datos nuevos.

- **Aprendizaje no supervisado:** el modelo trabaja con datos no etiquetados, el objetivo del algoritmo es descubrir patrones o estructuras en los datos sin la necesidad de ejemplos etiquetados, el sistema debe encontrar relaciones ocultas entre los datos.
- **Aprendizaje por refuerzo:** es un enfoque dinámico el modelo aprende al interactuar con el entorno, toma decisiones y recibe recompensas o penalizaciones, en base a las acciones que realiza. El objetivo es maximizar la recompensa total a lo largo del tiempo.

La incorporación de la inteligencia artificial y aprendizaje automático potencia los resultados del análisis de datos, permitiendo generar modelos predictivos. En el caso planteado para poder desarrollar modelos predictivos que identifiquen variedades de vino a partir de descripciones textuales (*variable description*), la inteligencia artificial y el aprendizaje automático deberán utilizar técnicas de procesamiento de lenguaje natural y clasificación (*aprendizaje supervisado*). Para poder entrenar al modelo se deben proporcionar datos de entrada y sus respectivas salidas (datos etiquetados) los datos de entrada son proporcionados por la variable *description* y los de salida por la variable *variety*.

Para saber si un modelo funciona se compara su predicción con la etiqueta real en datos de prueba. Es importante usar medidas que consideren el desbalance entre clases (por ejemplo, variedades con muchas o pocas reseñas).

La incorporación de la inteligencia artificial y aprendizaje automático potencia los resultados del análisis de datos, permitiendo generar modelos predictivos.

En cuanto a los beneficios de la aplicación de inteligencia artificial y aprendizaje automático algunos de ellos son:

- **Escalabilidad:** procesar miles de reseñas automáticamente.
- **Clasificación automática** de nuevos vinos según su descripción. Esto permite ahorrar tiempo en la creación de catálogos y sistemas de recomendación, ya que cuando hay un nuevo vino no es necesario hacerlo de forma manual.
- **Recomendaciones personalizadas** pueden sugerirse variedades similares basándose en el estilo sensorial deseado por el consumidor. Esto

Ciencia de Datos en reseñas de vinos mejora la experiencia de compra, beneficiando tanto a productores como a comerciantes.

- **Análisis** de estilo por región, permite detectar si ciertas descripciones están más asociadas a variedades específicas en ciertas regiones. Esto puede ayudar a los productores a posicionar sus vinos según el perfil sensorial dominante en su región.

La inteligencia artificial a través del aprendizaje automático le brinda tanto a productores como a comerciantes las herramientas para poder identificar posibles oportunidades mediante el uso del modelo predictivo como por ejemplo destacar productos que tendrán un alto potencial de comercialización.

Si bien la inteligencia artificial y el aprendizaje automático aportan una gran cantidad de beneficios, principalmente relacionados a la optimización del tiempo al realizar análisis de datos y a la toma de decisiones informada, existen ciertas limitaciones y desafíos para poder implementar estas herramientas.

Por ejemplo, cuando algunas variedades tienen muchas reseñas y otras muy pocas, se pueden aplicar soluciones sencillas como: agrupar las variedades con muy pocas muestras en una categoría para evitar ruido o usar técnicas que den más peso a las clases minoritarias durante el entrenamiento o evaluar el modelo por subgrupos (por país o por catador) para detectar sesgos. Estas medidas ayudan a obtener resultados más representativos

- La ambigüedad del lenguaje puede generar confusiones al desarrollar el modelo ya que este es subjetivo.
- Descripciones genéricas que no contienen rasgos distintivos por lo que no permiten distinguir variedades.
- Sesgos. Algunas variedades tienen muchas reseñas mientras que otras muy pocas, lo que puede sesgar el entrenamiento, tendiendo a favorecer a las variedades más frecuentes.
- Subjetividad. La reseña del crítico varía según el autor, el país o región lo que introduce ruido en los datos, ya que dos críticos pueden describir al mismo vino con estilos distintos, es decir, hacer una reseña de un vino utilizando palabras distintas con el mismo significado (sinónimos) y el modelo no las reconoce como equivalentes.

- Otra dificultad es la correcta limpieza y filtrado (procesamiento) de los datos, ya que si hay reseñas incompletas, repetitivas o mal escritas el modelo pierde precisión.

La Inteligencia Artificial y el Machine Learning pueden ser herramientas útiles para automatizar la clasificación de variedades a partir de descripciones, pero su éxito y correcto funcionamiento depende de la calidad y representatividad de los datos y mitigación de sesgos.

Limpieza, análisis y visualización de datos

¿Cómo puede la metodología de la ciencia de datos, incluyendo la limpieza de datos, el análisis exploratorio y la visualización, mejorar la comprensión de las preferencias y tendencias de consumo de vinos a partir de las reseñas disponibles?

El análisis de reseñas de vinos demuestra que, mediante la metodología de la ciencia de datos con un correcto tratamiento de la información se puede generar información y conocimientos de gran valor, que a simple vista no son detectables. Se deben describir las acciones de limpieza y exploración realizadas sobre el dataset, presentar visualizaciones clave que resuman las tendencias principales y extraer insights accionables para productores y comerciantes. Con la **limpieza de datos**, podemos garantizar la calidad y la coherencia del conjunto, eliminando errores, datos faltantes y ruido, para luego poder hacer un análisis confiable. Por ejemplo:

- Eliminación de duplicados exactos en reseñas idénticas para poder evitar sesgos en conteos y estadísticas.
- Eliminación de registros incompletos (sin *description*) ya que las reseñas sin descripción no servirán para el análisis textual.
- Normalización básica de texto (minúsculas y eliminación de espacios extra) para facilitar análisis textual (conteos o búsquedas de términos).

El **análisis exploratorio** permite descubrir patrones ocultos, también mediante agrupaciones o segmentación podemos entender la distribución del mercado y las tendencias de consumo.

Un primer análisis del archivo es explorar su composición, e identificar que datos contiene y de que tipo, por ejemplo, contiene reseñas con columnas como *description*, *variety*, *points*, *price*, *country*, *province*, *region_1* y *region_2* antes de analizarlo conviene calcular indicadores básicos (número de registros, % de valores nulos por columna, número de variedades únicas y concentración de las más frecuentes). Estos indicadores servirían para guiar las decisiones de limpieza y agrupamiento. Los objetivos de esta etapa son: garantizar la calidad y coherencia de los datos, explorar distribuciones y relaciones relevantes, visualizar hallazgos para facilitar decisiones comerciales y productivas.

La visualización de datos permite mostrar los hallazgos (insights) de forma clara y accesible, mostrando lo más importante, a través de gráficos intuitivos o dashboard interactivos. Con el enfoque interdisciplinario de la ciencia de datos podemos combinar estadística, programación, visualización y modelado para mejorar la comprensión de las preferencias, tendencias de consumo y ayudando a la toma de decisiones informada, lo que la convierte en una herramienta de suma importancia para afrontar los cambios que se generan gracias al avance tecnológico.

Algunas de las herramientas que se podrían utilizar para la representación visual podrían ser:

- **Distribución de puntuaciones (histograma):** muestra la distribución de las puntuaciones otorgadas. Permite ver en que valores se concentran las puntuaciones: bajos, medios o altos.
- **Distribución de precios (histograma en escala logarítmica):** este histograma busca reducir el efecto de valores extremos mostrando la forma real de la mayoría de los precios cuando hay algunos vinos muy caros que distorsionan la escala.
- **Relación precio vs. puntos (scatter con tendencia):** es un diagrama de dispersión donde cada punto representa un vino con su precio y su puntuación. Este gráfico muestra si existe correlación entre precio y calidad percibida.
- **Boxplots de puntos por top-10 variedades:** resume la distribución de puntuaciones para cada variedad: mediana, cuartiles y valores extremos. Para cada variedad se calcula la mediana, el primer y tercer cuartil y los outliers; se dibuja una caja y “bigotes”. Compara medianas y dispersión entre variedades y muestra cuáles son más consistentes y cuáles más variables.

Desde la perspectiva comercial esta metodología permite organizar los catálogos de forma eficiente, priorizar stock de variedades con alta mediana de puntos, ofrecer recomendaciones al cliente, adaptar estrategias de marketing según las preferencias de los consumidores, para así poder captar nuevos clientes.

Para los productores con el análisis de datos pueden comprender como sus vinos son percibidos en el mercado y así ajustar procesos de elaboración, promocionar catas para variedades con alta variabilidad de puntuación para así mejorar posicionamiento y percepción. También pueden realizar comparaciones de desempeño con el de otras regiones o bodegas. Otro beneficio es la detección de tendencias emergentes para así

Ciencia de Datos en reseñas de vinos
tomar decisiones estratégicas en cuanto a producción.