



CIENCIA DE DATOS EN REÑAS DE VINOS

Violeta Francescangeli
17/05/2026

Índice

Índice	pág. 1
Carga y verificación del archivo	pág. 2
Análisis exploratorio de datos	pág. 3
Tratamiento de datos faltante	pág. 11
Análisis de datos atípicos	pág. 14

Carga y verificación del archivo

En esta primera etapa se llevó a cabo el proceso de carga, verificación y preparación inicial del conjunto de datos utilizando Python (Jupyter Notebook). El objetivo fue asegurar que el archivo estuviera correctamente formateado y listo para el análisis exploratorio posterior.

El archivo original se encontraba en formato .xlsx, por lo que fue necesario convertirlo a formato .CSV, que es el requerido para su lectura eficiente en Python. Al realizar la conversión se detectaron cuatro filas con errores de formato (mayor cantidad de columnas que las demás) que impedían la carga correcta del dataset. Dado que representaban una proporción mínima respecto del total (130.000 filas), decidí eliminarlas para garantizar la correcta importación del archivo.

Una vez corregido el archivo, se procedió a cargarlo en un entorno de Jupyter Notebook, la carga se realizó sin inconvenientes luego del tratamiento previo. Para ello instale y cargue las bibliotecas necesarias para el análisis de datos, principalmente:

- pandas para la manipulación del dataset
- numpy para operaciones numéricas
- matplotlib y seaborn para visualización

Tras la importación, realice una revisión inicial para confirmar que el archivo se hubiera cargado correctamente. Chuequee:

Cantidad de filas y columnas: se verificó que el dataset conservara su tamaño esperado (129972 registros y 16 columnas). Inspeccione las primeras filas de la dataset para corroborar que no hubiera desplazamientos, columnas mal alineadas o valores corruptos. Tipos de datos: se revisaron los tipos asignados automáticamente por Python a cada columna, identificando variables numéricas (como points y price) y categóricas (como country, variety, winery, entre otras). Las variables numéricas fueron convertidas ya que estas habían sido identificadas como texto.

Análisis exploratorio de datos

Con el dataset correctamente cargado y validado, comencé con el análisis exploratorio de datos (EDA) en Python.


Hice una primera observación general de las variables presentes, la identificación de valores faltantes, cuáles eran las columnas con mayor cantidad de datos null.

Variable Points

La variable points es una variable de tipo numérica. Presenta una baja cantidad de datos nulos por lo que se podía proceder con un análisis inicial.

Lo primero fue usar la función describe() para tener un panorama general, como saber la cantidad de datos válidos, su mínimo y máximo para identificar si había valores imposibles, como valores muy altos o negativos, en este análisis identifique un valor fuera de rango por lo que precede a descartarlo en el análisis para que no generar distorsión en los gráficos a realizar posteriormente. A parte de eso, los demás datos proporcionados por la función se veían ‘normales’

Histograma de la variable points



El histograma muestra la distribución de la variable points, que corresponde al puntaje asignado a cada vino en el dataset. En el eje horizontal se muestran los valores de puntaje (de 0 a 100), mientras que el eje vertical indica la frecuencia de aparición de cada

rango de puntuaciones. Además, se incluyen tres estadísticas descriptivas clave:

mínimo: 80, máximo: 100 y media: 88.45.


La variable `points` muestra una distribución estable, concentrada y sin valores atípicos, lo que facilita su análisis. La ausencia de puntajes bajos indica que la escala está sesgada hacia evaluaciones positivas. La forma de la distribución sugiere que los puntajes no discriminan fuertemente entre vinos, ya que la mayoría se agrupa en un rango estrecho. Esta variable es adecuada para correlacionar con otras, como `price`, para estudiar la relación entre calidad percibida y valor económico.

Variable price

La variable `price` es una variable de tipo numérica. Presenta una baja cantidad de datos nulos, aunque mayor que la variable `points`, se podía proceder con un análisis inicial.

Al igual que con la variable `points` lo primero fue usar la función `describe()` para tener un panorama general, como saber la cantidad de datos válidos, su mínimo y máximo para identificar si había valores imposibles, como valores muy altos o negativos, en este análisis identifique un valor fuera de rango, lo descarte del análisis para que no generara distorsión en los gráficos a realizar posteriormente. A parte de eso, los demás datos proporcionados por la función se veían ‘normales’.

Histograma de la variable price



El histograma de la variable `price` muestra cómo se distribuyen los precios de los


vinos del dataset. En el eje horizontal se representan los valores de precio (en USD), y en el eje vertical indica la frecuencia con la que aparece cada rango de precios. Además, se incluyen estadísticas descriptivas como el mínimo, máximo y media.

La mayoría de los vinos tiene precios bajos o moderados, concentrándose en los primeros rangos del histograma. Existe una cola larga hacia la derecha, correspondiente a vinos de precios elevados que aparecen con muy poca frecuencia. Los valores extremos (outliers) influyen en la forma general de la distribución y elevan la media.

El precio mínimo es bajo, lo que indica la presencia de vinos económicos. El precio máximo es considerablemente alto, lo que confirma la existencia de vinos premium o de edición limitada. La media queda desplazada hacia la derecha debido a los valores extremos, por lo que no representa el “precio típico” del dataset.

La distribución no es simétrica: está fuertemente sesgada hacia la derecha. La mayor parte del mercado representado corresponde a vinos de gama baja y media. Los vinos de precio muy elevado son pocos, pero influyen en las medidas de tendencia central. Para análisis posteriores puede ser útil analizar por separado el segmento premium.

Grafico de dispersión price vs points




El scatter plot muestra la relación entre el precio y la puntuación de cada vino. Cada punto representa un vino individual. Se observa una tendencia general ascendente: a mayor puntaje, mayor precio, pero la relación no es estrictamente lineal: Hay vinos con alta puntuación y precio moderado. Y también hay vinos caros con puntuaciones no tan altas (promedio). Esto indica que la puntuación influye en el precio, pero no lo determina completamente. Existe una correlación débil o moderada.

Variables categóricas country, winery y variety

Para las tres variables (country, winery y variety) al no poder utilizar la función describe() se hizo un pequeño análisis previo en el cual denotamos cantidades de valores nulos, cantidad de datos, cantidad de países, variedades y bodegas distintas había, también vimos las frecuencias de cada uno de estos.


Grafico de barras variable country




El gráfico presenta un barplot horizontal que muestra los 10 países con mayor cantidad de vinos registrados en el dataset. En el eje vertical se listan los países, y en el eje horizontal se representa la cantidad de vinos asociados a cada uno. Los valores exactos aparecen junto a cada barra, lo que facilita la comparación entre países. Se puede ver una distribución desigual entre países. Estados Unidos domina ampliamente el dataset. Esto no implica necesariamente que EE.UU. produzca más vino, sino que la base de datos tiene un fuerte sesgo hacia vinos reseñados en el mercado estadounidense. A partir del cuarto lugar, la cantidad de vinos disminuye notablemente, mostrando que el dataset está

concentrado en pocos países. Esta distribución debe tenerse en cuenta en análisis posteriores, ya que puede generar sesgos en comparaciones entre países.


Gráfico de barras variable variety



El gráfico presenta un barplot horizontal que muestra las 10 variedades de uva más comunes dentro del dataset. En el eje vertical se listan las variedades, y el eje horizontal indica la cantidad de vinos registrados para cada una. Se incluyen los valores exactos para facilitar la comparación. El dataset está dominado por un conjunto reducido de variedades, lo que indica una alta concentración en ciertos tipos de uva. La variable *variety* presenta una distribución desigual, con algunas variedades muy dominantes. La fuerte presencia de algunas variedades puede estar influenciada por la composición geográfica del dataset. Esta concentración debe considerarse en análisis posteriores, ya que puede generar sesgos si se comparan variedades con tamaños de muestra muy diferentes.

Gráfico de barras variable winery


El gráfico muestra un barplot horizontal con las 10 bodegas que poseen mayor cantidad de vinos registrados en el dataset. En el eje vertical se listan las bodegas, y el eje horizontal indica la cantidad de vinos asociados a cada una. Se incluyen los valores exactos para facilitar la comparación. La cantidad total de bodegas distintas en el dataset es de 18290. La diferencia entre la primera y la décima bodega no es tan grande como en otras variables (como *country*), lo que sugiere una distribución más equilibrada dentro del top 10. La presencia de bodegas de distintos países indica diversidad geográfica dentro del top 10. Este tipo de gráfico permite identificar productores con mayor peso en el dataset, lo cual es útil para análisis comparativos entre bodegas,

Gráfico de barras cantidad de bodegas por país

El gráfico muestra un barplot horizontal que representa los 10 países con mayor cantidad de bodegas registradas en el dataset. En el eje vertical se listan los países, y el eje horizontal indica la cantidad de bodegas asociadas a cada uno. Se incluyen los valores exactos para facilitar la comparación. La distribución es muy desigual en la cantidad de bodegas por país. Estados Unidos lidera ampliamente, lo que refleja nuevamente el sesgo del dataset hacia el mercado norteamericano.


La variable *country* muestra una alta concentración de bodegas en pocos países, especialmente en Estados Unidos. Esta distribución debe considerarse en análisis posteriores, ya que puede generar sesgos si se comparan países con tamaños de muestra muy diferentes.

Gráficos de barras top 10 países con mayor puntaje y precios promedio



Los países con mayor puntaje promedio no necesariamente son los más representados en el dataset. Esto sugiere que los vinos reseñados de estos países tienden a ser de alta calidad, o que las reseñas disponibles están sesgadas hacia vinos premium. La diferencia entre los puntajes es pequeña (entre 88 y 92), lo que indica que la escala de evaluación es muy estrecha y concentrada en valores altos.

Comparando ambos gráficos se observa que el puntaje promedio no siempre está directamente relacionado con el precio promedio. Algunos países logran vinos de alta calidad sin precios excesivos, y otros países tienen vinos caros, pero no necesariamente mejor puntuados. La presencia de países con pocos vinos, pero puntajes altos sugiere un posible sesgo de selección hacia vinos premium.

Top 10 bodegas con mayor puntaje y precio promedio

Los gráficos muestran que existen bodegas con vinos excelentes y relativamente accesibles, y otras con vinos muy caros, pero no necesariamente mejor puntuados. La relación entre precio y puntaje es compleja y no lineal, lo que justifica analizar ambas variables por separado.

Tratamiento de datos faltantes

Para comenzar el tratamiento de datos faltantes debemos comenzar por identificarlos. Para poder evaluar y luego decidir su correcto tratamiento. El primero que realice fue un conteo de datos faltantes por columna (variable) y luego el calculo del porcentaje y ordenarlos en una tabla según la variable con mayor porcentaje de valores nulos.

	Faltantes	Porcentaje
region_2	78905	60.71
designation	37130	28.57
taster_twitter_handle	31295	24.08
taster_name	26378	20.30
region_1	21080	16.22
price	9741	7.49
points	1257	0.97
title	253	0.19
variety	156	0.12
province	152	0.12
winery	103	0.08
country	63	0.05
id_original	1	0.00
description	0	0.00

Como podemos ver la variable `region_2` es la mas afectada por datos nulos con más del 60%, luego la siguen `designation` con un porcentaje bastante menor del 28% y

taster_twitter_handle con 24%. Las tres variables con variable categóricas. El top 5 de variables con mas datos faltantes son categóricas, las variables numéricas no presentan un alto porcentaje.

Existen diferentes estrategias para el manejo de datos faltantes algunas de ellas son:

- La eliminación de filas suele utilizarse cuando la cantidad de faltantes es muy baja y no afecta el tamaño del dataset.
- Imputación con medidas estadísticas, calculamos media, mediana, moda de la variable a tratar y remplazamos los datos faltantes por ese valor. Se usa en variables numéricas cuando los faltantes son pocos y la distribución no se distorsiona.
- Imputación con categorías especiales como, "Unknown", "Sin dato", "No especificado" para variables categóricas esto evita inventar información. Esta estrategia es útil si el porcentaje es bajo ya que de lo contrario generaríamos 'ruido' innecesario.
- Eliminación de columnas. Cuando una variable presenta un alto porcentaje de datos faltantes, es difícil poder sacar información confiable o útil de ella por lo que lo mejor sería eliminarla.
- Otra opción es mantener NaN ya que a veces es la mejor opción, especialmente en análisis exploratorio, para no introducir sesgos.

Para la variable región_2 que tiene un alto porcentaje de datos faltantes (mayor al 50%), esto sugiere una columna muy incompleta, ya que mas de la mitad de los registros no poseen datos, lo que genera que sea de poca utilidad para el análisis. Rellenarla generaría ruido innecesario, al ser una variable categórica no podemos estimarlas, por lo cual la mejor opción sería eliminarla.

Para las columnas categóricas como designation, taster_name, taster_twitter_handle, etc. que tienen faltantes moderados se podría imputar con "Unknown" o "Sin dato". En variables categóricas, imputar con una categoría especial ("Unknown") permite conservar los registros sin inventar información y sin distorsionar la distribución de categorías existentes. Porque si bien no es tan alto el porcentaje de faltantes, si es significativo para eliminar registros, lo que podría afectar el análisis de otras variables

Las columnas numéricas con pocos faltantes como price y points la mejor opción sería mantener NaN o imputar con mediana, imputar con 0 no sería adecuado porque en price no representa un valor real y además distorsiona los análisis.

En la variable price se observan valores extremos (outliers) que forman parte natural de la distribución, ya que existen vinos de muy alto precio. Si bien la mediana es una medida robusta frente a outliers, su uso como imputación puede distorsionar el análisis al reducir artificialmente la variabilidad y subestimar el valor real de los vinos faltantes.

Por este motivo, decidí no imputar los valores faltantes de price, manteniendo los NaN para evitar introducir información artificial que alteré la distribución original, para así preservar la estructura real del conjunto de datos y evitar sesgos en análisis futuros.

La variable points no presenta gran cantidad de valores faltantes en el conjunto de datos, por eso, no es necesario aplicar técnicas de imputación. Además, la escala de puntaje es acotada (80–100 puntos) y no contiene outliers reales. Los valores atípicos detectados, como el puntaje 777, corresponden a errores de carga y fueron eliminados desde el comienzo, ya que no forman parte de la escala válida. Por lo que la variable points se mantiene sin imputación y únicamente se corrigieron los valores inválidos.


Análisis de datos atípicos

Se realizó la detección de valores atípicos en las variables numéricas del dataset utilizando el método del rango intercuartílico (IQR).

Antes de aplicar el método IQR para detectar valores atípicos en la variable price, se filtraron los registros con valores iguales a 0 o negativos, ya que estos no representan precios válidos. En la variable price se detectan valores atípicos correspondientes a vinos de muy alto precio. Los valores atípicos detectados corresponden únicamente a precios mayores al límite superior. Estos outliers no representan errores, sino características reales del mercado del vino, donde existen productos con valores significativamente superiores al promedio, por lo que se los considera outliers naturales y se mantienen en el análisis. El límite inferior resultó negativo y, dado que no existen precios negativos en el dataset, no se identificaron outliers inferiores.

En la variable points no existen outliers naturales, ya que la escala de puntaje utilizada se encuentra acotada entre 80 y 100 puntos. Los valores atípicos detectados corresponden a errores de carga y fueron eliminados, por lo que no fue necesario detectar outliers.

Boxplot de la variable price




El boxplot de la variable price muestra una distribución altamente asimétrica hacia la derecha, con una gran cantidad de valores atípicos correspondientes a vinos de alto

precio. La mayor parte de los vinos se concentra entre 10 y 40 USD, mientras que el bigote superior se extiende hasta aproximadamente 80 USD.

Por encima de ese valor se observa una gran cantidad de puntos individuales considerados outliers. Estos valores corresponden a vinos de gama alta o premium.

La presencia de tantos outliers indica una cola larga en la distribución, típica de variables económicas como el precio. El intervalo fue cortado hasta 300usd para una mejor visualización ya que el valor mas alto de precios llega a mas de 3000 USD.


Boxplot de la variable price sin outliers




Al eliminar los outliers superiores, el boxplot permite visualizar con mayor claridad la distribución central del precio. La mayoría de los vinos se encuentran entre 10 y 40 USD. Este gráfico confirma que los outliers corresponden a una minoría y no afectan la forma del cuerpo principal de la distribución, sino únicamente la cola derecha.

Boxplot de outliers de la variable price

El boxplot de outliers muestra una amplia dispersión entre los vinos de alto precio, lo que indica que dentro del segmento premium existe una gran variabilidad. Estos valores no representan errores, sino características reales del mercado del vino.



Boxplot de la variable points



El boxplot de la variable points muestra una distribución muy concentrada entre 80 y 100 puntos. No se observan outliers naturales, ya que la escala está acotada y controlada. Los únicos valores atípicos detectados previamente (como 777 puntos) correspondían a errores de carga y fueron eliminados. La ausencia de outliers reales indica que la variable points es estable y no presenta valores extremos que puedan distorsionar el análisis.