



CIENCIA DE DATOS EN REÑAS DE VINOS

Violeta Francescangeli

07/06/2026

Índice

Índice	pág. 1
Diseño de la base de datos	pág. 2
Implementación del modelo	pág. 3
Consultas SQL avanzadas	pág. 4
Análisis multidimensional	pág. 5

Diseño de la base de datos

El dataset original contiene 130.000 registros de reseñas de vinos, con información sobre país, variedad, bodega, puntaje, precio y descripciones textuales. Los datos utilizados provienen de un proceso ETL previo para mejorar la calidad del dataset original, en este proceso se realizaron tareas de limpieza que incluyeron la imputación de valores faltantes, la estandarización de formatos y la eliminación de filas que presentaban errores estructurales o inconsistencias.

Antes de poblar las tablas finales, se decidió incorporar una tabla staging (load table) como paso intermedio. Esta tabla funciona como un espacio de carga temporal donde se almacena el dataset completo sin restricciones ni validaciones estrictas. Con esta tabla se evitan errores de carga, garantizando que todos los datos se carguen, para luego hacer una validación posterior. También facilita la normalización ya que se poblarán las tablas normalizadas utilizando como fuentes a esta.

El dataset original se presenta en un formato plano, donde toda la información se encuentra en una única tabla. Para mejorar la calidad del modelo, evitar redundancias, y realizar consultas más eficientes, se aplicará un proceso de normalización siguiendo las tres primeras formas normales. Realizando este proceso podemos obtener un modelo más eficiente, escalable y fácil de consultar.

Primera Forma Normal (1FN)

- Cada columna contiene un único valor.
- No existen listas ni campos compuestos.
- Todas las filas presentan la misma estructura.

Segunda Forma Normal (2FN)

- Se identifican entidades que se repiten (en este caso país, provincia, región, variedad, bodega).
- Se separan en tablas independientes para evitar duplicación de información.

Tercera Forma Normal (3FN)

- Se eliminan dependencias transitivas.

A partir del análisis del dataset y del proceso de normalización, se definieron las siguientes entidades principales:

Country (país): representa el nivel geográfico más general asociado a cada vino y se relaciona con la tabla province en una relación uno-a-muchos. Esta tabla se crea para evitar la repetición de nombres de países en la tabla principal. Esta tabla tendrá: Identificador único del país (id_country) (PK) que permitirá relacionar cada país con sus provincias correspondientes y nombre del país (country_name).

Province (Provincia): representa subdivisiones geográficas dentro de cada país. Permite organizar la información de manera jerárquica y evitar redundancias en la tabla de reseñas. Actuará como nivel intermedio entre país y región, y se relacionará con *region* en una relación uno-a-muchos. Conformada por las columnas: Identificador único de la provincia (id_province) (PK), nombre de la provincia (province_name), e Identificador del

país al que pertenece (`id_country`) (FK), de esta forma se garantiza la integridad referencial y evita inconsistencias.

Region (Región): representa áreas geográficas más específicas dentro de una provincia. No todos los vinos poseen información de región. Compuesta por, Identificador único de la región (`id_region`) (PK), nombre de la región (`region_name`), e Identificador de la provincia asociada (`id_province`) (FK).

Variety (Variedad de uva): contiene los distintos tipos de uvas utilizados en los vinos del dataset. Dado que muchas reseñas comparten la misma variedad, esta dimensión evita redundancia de información, además permitiera agrupar vinos por tipo de uva. Identificador único de la variedad (`id_variety`) (PK), nombre de la variedad (`variety_name`).

Winery (Bodega): representa las bodegas o productores asociados a cada vino. Se crea para evitar información redundante, ya que una bodega puede aparecer en más de un vino reseñado. Identificador único de la bodega (`id_winery`) (PK), nombre de la bodega (`winery_name`).

Taster(taster name): representa a los catadores, estos constituyen una entidad real con atributos asociados y son relevantes para el análisis. Esta tabla contiene `id_taster` (Pk), nombre del catador (`taster_name`) y su usuario `taster_twitter_handle`

Wine Review (Reseña de vino): funciona como tabla de hechos y contiene la información principal de cada registro del dataset, descripción del vino (`description`), puntaje otorgado (`points`), precio (`price`), claves foráneas hacia país, provincia, región, variedad y bodega (`id_country`), (`id_province`), (`id_region`), (`id_variety`), (`id_winery`).

Las variables *price* y *points* permanecerán dentro de la tabla *wine_review*, porque son valores numéricos continuos, no aportan significado conceptual como dimensiones y se generarían tablas innecesariamente grandes. Por lo tanto, no se crearán tablas independientes para estas variables, incluso si algunos valores se repiten. Tampoco se crearon dimensiones para `region_1`, `region_2`, `designation`, y `description` ya que presentan alta cantidad de valores nulos.

Implementación

Proceso de limpieza y carga del dataset

Se realizó un proceso de limpieza, depuración y preparación del dataset utilizando Python y la librería *pandas*. El archivo original presentaba inconsistencias estructurales, como encabezados desplazados, filas corruptas, columnas vacías y valores residuales (“;;;”) que impedían su correcta lectura. En primer lugar, se cargó el archivo sin encabezado y se reconstruyó la fila de nombres de columnas, eliminando las filas defectuosas. Luego se renombraron columnas mal formadas y se eliminaron 2 columnas con en su gran mayoría datos nulos. Una vez normalizada la estructura del Data Frame, se estableció una conexión con MySQL y se cargaron los datos en una tabla staging denominada *loadtable_wines*, la cual servirá como base para el posterior modelado, normalización y análisis dentro del sistema gestor de bases de datos.

Luego de la carga de datos a la tabla `loadtable_wines`, se verificó la correcta carga del dataset y luego se procedió a la creación de las tablas dimensión: `country`, `province`, `variety`, `winery` y `tester`, con sus respectivas primary key.

Los valores textuales fueron normalizados mediante `LOWER()` y `TRIM()` durante la población de cada tabla para evitar duplicados generados por diferencias de formato. Posteriormente, se limpiaron los campos numéricos (`points` y `price`) reemplazando valores no válidos por `NULL`. Se creó la tabla de hechos `wine_reviews`, que almacena las reseñas y referencia a las dimensiones mediante claves foráneas.

Se utilizó la cláusula `LIMIT` en la carga de la tabla de hechos para evitar duplicados ya que, cuando se realizaba la inserción completa sin `LIMIT`, se producían filas duplicadas.

Al aplicar `LIMIT` se garantiza que la cantidad de registros insertados coincida exactamente con la cantidad de filas de la tabla `loadtable_wines`.

Finalmente, se verificó que la cantidad total de registros cargados coincidiera con el total de filas de la tabla `loadtable_wines`, garantizando la integridad del proceso.

Consultas SQL avanzadas

Cantidad de vinos por país

Se realizó una consulta para obtener la cantidad de vinos por país. La tabla de hechos `wine_reviews` se unió con la dimensión `t_country` mediante la clave foránea `id_country`. Luego se aplicó un `GROUP BY` para agrupar los registros por país y un `COUNT(*)` para contabilizar la cantidad de vinos asociados a cada uno. Por último, con `ORDER BY ... DESC`, los resultados se ordenan de mayor a menor para identificar los países con mayor presencia en el dataset.

Precio promedio según puntuación

Para analizar la relación entre la calificación de un vino y su precio, se calculó el precio promedio asociado a cada puntaje. Se utilizó la función `AVG()` sobre la columna `price`, filtrando previamente los valores nulos para evitar distorsiones. Luego se agruparon los resultados por puntaje mediante `GROUP BY` y se ordenaron de forma ascendente. Esta consulta permite observar cómo varía el precio promedio a medida que aumenta la puntuación.

Bodegas con más vinos en el dataset

Para identificar las bodegas con mayor cantidad de vinos reseñados en el conjunto de datos, se realizó una consulta agregada sobre la tabla de hechos `wine_reviews`, unida a la tabla `t_winery`. Se utilizó `COUNT(*)` para contabilizar la cantidad de vinos asociados a cada bodega y se aplicó un `GROUP BY` para agrupar los resultados por nombre de bodega. Finalmente, los resultados se ordenaron de mayor a menor y se limitó con `LIMIT` para que solo se muestre el Top 10.

Variedades más comunes por región (region_1)

Se analizó la distribución de variedades dentro de la región 1. Para ello, se unió la tabla de hechos con la dimensión de variedades y se agruparon los registros por región y variedad. Esta consulta permite identificar qué variedades predominan en cada región.

Variedades más comunes por (region_2)

Se realizó un análisis similar al de region_1, pero aplicado a la subregión (region_2). La consulta agrupa los vinos por región_2 y variedad, permitiendo identificar patrones más específicos dentro de zonas geográficas más pequeñas. Con este análisis se complementa la visión general de region_1 y permite detectar subregiones con especialización varietal marcada.

4. Análisis multidimensional:

Precio promedio por país y variedad

Muestra para cada país, qué variedades son más caras. Se realizó un análisis multidimensional país-variedad-precio para identificar qué variedades presentan mayor precio en cada país. Se calculó el precio promedio agrupando por país y variedad, se filtraron variedades con menos de 20 registros para evitar ruido y variedades con poca cantidad de vinos.

Puntaje promedio por país y variedad

Similar a la consulta anterior de precio, esta consulta muestra qué variedades obtienen mejores puntajes en cada país. Para ello, se calculó el puntaje promedio por país y variedad, permitiendo identificar qué estilos de vino reciben mejores evaluaciones en cada región (país) productora.

Relación entre precio y puntaje por país

En esta consulta podemos analizar cómo se relacionan el precio y la calidad percibida de los vinos en cada país, para eso se calcula el precio y el puntaje promedios agrupados por país. Así podemos ver si los vinos más caros de cada país son también los que tienen mayor puntaje o sino necesariamente para tener un mayor puntaje deben ser costosos.

Ranking de variedades por país

Las combinaciones país-variedad con mejor puntaje promedio. Se genera un ranking multidimensional país-variedad calculando el puntaje promedio para cada combinación país-variedad, como filtro se pone que las combinaciones deben tener al menos 30 vinos y luego se ordena de mayor a menor puntaje. Este análisis permite identificar combinaciones destacadas y ver con que países y con que variedades destaca cada uno.

Variedades más producidas por país

Se realizó un análisis multidimensional país-variedad para identificar cuáles son los vinos más representativos de cada país. La consulta agrupa los registros por país y variedad, calcula la cantidad de vinos asociados a cada combinación y luego aplica un ranking interno para obtener las tres variedades más frecuentes en cada país. Con este análisis podemos visualizar la especialización vitivinícola de cada país, mostrando qué estilos de vino dominan en cada región productora

Distribución de vinos por país y rango de precio

Se realiza un análisis multidimensional entre país-rango de precio para identificar cómo se distribuyen los vinos dentro de cada país según segmentos económicos. La consulta

clasifica los vinos en intervalos de precio y calcula la cantidad de vinos y el puntaje promedio en cada categoría. Este análisis permite observar la cantidad de vinos que tiene cada país en un rango de precio y la puntuación que estos recibieron.

Ranking multidimensional de países según puntaje promedio

Se construyó un análisis multidimensional que integra puntaje promedio, precio promedio, volumen total de vinos reseñados y la bodega más representada en cada país. Primero se calcularon los promedios de puntaje y precio, junto con la cantidad total de vinos reseñados por país. Luego se generó un ranking ordenando los países de mayor a menor puntaje promedio. Además, se identificó la bodega con más reseñas en cada país y se calculó el porcentaje que representan sus vinos respecto del total del país. Este análisis permite comparar países por calidad y precio, como también por volumen y concentración de productores.