



CIENCIA DE DATOS EN REÑAS DE VINOS

Violeta Francescangeli
28/06/2026

Índice

Índice	pág. 1
Selección y depuración de datos	pág. 2
Contextualización y preguntas clave	pág. 6
Creación de visualizaciones efectivas	pág. 8
Interpretación y presentación	pág.30

Selección y depuración de datos

En este trabajo se utilizó un conjunto de datos basado en reseñas de vinos. El dataset contiene información relevante para el análisis, como: país de origen, bodega (winery), variedad de uva (variety), precio (price), puntuación (points), descripción del vino (description).

Antes de comenzar el análisis, se realizó un proceso de depuración para corregir problemas en el archivo, algunas de estas correcciones fueron realizadas en power query en detalladas en el TP2. Algunas de las correcciones realizadas durante la realización del trabajo práctico fueron: delimitadores inconsistentes, filas con errores de formato, columnas de tipo numéricas con valores no numéricos, presencia de caracteres extra (por ejemplo, “;;;” en la columna winery).

Una vez que fueron corregidos estos problemas, se cargó el archivo final `set_datos_arreglo.csv`, que contiene los datos limpios y listos para el análisis.

Carga del dataset

Para trabajar con el archivo depurado, se utilizó la librería pandas, que permite manipular datos de forma eficiente. Se configuró el entorno para mostrar valores numéricos con dos decimales y se cargó el archivo utilizando `engine="python"` y `sep=None`, para permitir a pandas detectar automáticamente el delimitador correcto.

La visualización inicial con `df.head()` se realizó para poder verificar que las columnas y los tipos de datos fueran los esperados.

Depuración y reconstrucción del dataset

Durante la exploración inicial del archivo se identificaron problemas en su estructura, estos fueron: la primera fila no correspondía a un encabezado válido, sino que los tenía la segunda fila, existían inconsistencias en el delimitador, por lo que fue necesario especificar `sep=";"`.

Para corregir estos problemas, se realizó lo siguiente:

- Leer el archivo sin encabezados (`header=None`) para evitar que pandas asignara nombres incorrectos como `Column1`, `Column2`, etc.
- Extraer la fila 1 como lista de nombres de columnas, ya que contenía los encabezados correctos.
- Eliminar las dos primeras filas del archivo, que no formaban parte de registros válidos.
- Asignar los encabezados reales al DataFrame final.

Este proceso permitió reconstruir correctamente la estructura del dataset, garantizando que cada columna tuviera su nombre correspondiente y que los datos estuvieran alineados con la estructura original utilizada en MySQL.

Limpieza de columnas y estandarización de nombres

Luego de reconstruir la estructura del dataset, se identificaron problemas relacionados con columnas incompletas y nombres incorrectos. Estos fueron:

- Las dos últimas columnas del archivo contenían casi exclusivamente valores nulos, por lo que se decidió eliminarlas para evitar ruido en el análisis.
- La primera columna no tenía un nombre válido debido a errores en el archivo original. Para mantener coherencia con la base de datos utilizada en MySQL, se renombró como `num_resena`, que representa el identificador de cada reseña.
- La columna `winery` presentaba un problema tanto en su nombre como en sus valores: aparecía como `"winery;;;"` y además cada fila contenía varios puntos y coma al final. Se corrigió el nombre de la columna y se limpió la columna eliminando los caracteres innecesarios.

Estas transformaciones permitieron obtener un DataFrame más consistente, con nombres de columnas claros y sin información redundante o corrupta, fundamental para garantizar que las etapas posteriores de análisis y visualización se realicen sobre datos confiables.

Conversión de columnas numéricas y tratamiento de valores inválidos

Las columnas `points` (puntuación del vino) y `price` (precio) son variables numéricas fundamentales para el análisis. Sin embargo, durante la inspección inicial se detectó que ambas contenían valores almacenados como texto debido a inconsistencias en el archivo original. Para corregir este problema, se aplicó la función `pd.to_numeric()` con el parámetro `errors='coerce'`, que convierte automáticamente: Valores numéricos válidos a tipo float y valores no numéricos o corruptos a **NaN**

Este procedimiento es importante para: permitir cálculos estadísticos confiables, evitar errores en visualizaciones, identificar valores atípicos o inconsistentes, mantener la integridad del análisis exploratorio


Luego de la conversión, se verificaron los tipos de datos del DataFrame para confirmar que ambas columnas quedaron correctamente definidas como numéricas.

Imputación de valores faltantes en variables categóricas

Para completar el proceso de limpieza del dataset, se imputaron los valores faltantes de las variables categóricas utilizando la categoría “Unknown”. Esta estrategia se realizó para columnas con porcentajes de datos nulos moderados, para poder preservar todos los registros sin tener que eliminarlos ya que no existía información suficiente para realizar una imputación más precisa. Las columnas imputadas fueron: designation, taster_name, taster_twitter_handle, region_1, title, variety, province, winery y country.

Luego de la imputación, el porcentaje de nulos en estas variables se redujo a **0%**, se evitó la pérdida de información por eliminación de registros, y el dataset quedó completamente preparado para análisis exploratorios, gráficos y modelos posteriores.

Porcentaje de valores nulos por variable



Para evaluar la calidad del dataset y determinar qué variables requieren imputación o eliminación, se calculó el porcentaje de valores nulos por columna. Esta métrica es fundamental para comprender el nivel de completitud de los datos.

Se construyó un gráfico de barras horizontal donde:

- Cada barra representa una variable del dataset.
- El largo de la barra indica el **porcentaje de valores faltantes**.
- El eje X se limitó al rango **0–80%**, ya que ninguna variable supera ese nivel de ausencia.

Este análisis permite identificar:


- Variables con muy pocos valores faltantes, que pueden utilizarse sin necesidad de imputación.
- Variables con porcentajes moderados de nulos, donde la imputación puede ser una estrategia adecuada.
- Variables con altos porcentajes de nulos, que podrían descartarse o requerir un tratamiento especial.

Tabla resumen de valores nulos por variable

Además del gráfico de porcentaje de valores faltantes, se elaboró una tabla resumen que muestra para cada variable: cantidad absoluta de valores nulos, porcentaje de nulos respecto del total de filas.

La tabla se ordenó de mayor a menor cantidad de valores faltantes, lo que permite identificar rápidamente: variables con altos niveles de ausencia, que pueden requerir imputación avanzada o eliminación. Variables con niveles moderados de nulos, donde la imputación simple puede ser suficiente. Variables con muy pocos o ningún valor faltante, que pueden utilizarse directamente en el análisis.

Porcentaje de valores nulos después de la imputación



Luego de imputar las variables categóricas con la categoría “Unknown”, se recalculó el porcentaje de valores faltantes por columna. El nuevo gráfico muestra que: todas las variables categóricas imputadas pasaron a tener 0% de valores nulos. Las únicas columnas que mantienen valores faltantes son aquellas que no fueron imputadas (por ejemplo, variables numéricas como *price* o *points*). El nivel general de completitud del dataset mejoró significativamente, permitiendo continuar con el análisis sin eliminar registros.

Este gráfico confirma visualmente que la imputación fue exitosa y que el dataset quedó en condiciones óptimas para realizar análisis exploratorios, comparativos y modelado posterior.

Contextualización y preguntas clave

Preguntas clave asociadas a los gráficos

Distribución de puntos y precios

- ¿Cómo se distribuyen los puntajes otorgados por los críticos?
- ¿El precio de los vinos presenta una distribución homogénea o está sesgado hacia ciertos rangos?
- ¿Existen outliers que puedan influir en el análisis?

Top 10 países, variedades y bodegas

- ¿Qué países y variedades son los más representados en el dataset?
- ¿Qué bodegas tienen mayor presencia y cómo podría influir eso en el mercado?

Boxplots por país y variedad

- ¿Qué países presentan vinos más consistentes en calidad?
- ¿Qué variedades muestran mayor variabilidad en los puntajes?
- ¿Qué regiones se destacan por tener vinos mejor valorados?

Scatter Precio–Puntos (escala log)

- ¿Existe relación entre el precio y el puntaje?
- ¿Los vinos premium justifican su precio con mejores calificaciones?
- ¿Hay vinos económicos con puntajes altos?

QPR (Quality–Price Ratio)

- ¿Qué vinos ofrecen el mejor rendimiento por cada dólar invertido?
- ¿Qué países o variedades destacan en relación calidad–precio?
- ¿El QPR está influido más por el precio o por el puntaje?

Heatmap de correlaciones

- ¿Qué variables numéricas están relacionadas entre sí?
- ¿El precio predice la calidad?
- ¿Qué tan útil es el QPR como métrica complementaria?

Análisis de texto (word cloud, frecuencias, comparaciones)

- ¿Qué atributos sensoriales mencionan con mayor frecuencia los críticos?
- ¿El lenguaje cambia entre vinos de alta y baja calidad?
- ¿Qué características destacan en los vinos mejor puntuados?

Para comprender el comportamiento del mercado del vino y analizar los factores

que influyen en la calidad percibida por los críticos, se plantearon una serie de preguntas orientadoras que guiaron el análisis exploratorio. Estas preguntas permitieron contextualizar el dataset y definir los objetivos principales del estudio.

En primer lugar, se buscó identificar qué países, variedades y bodegas dominan la oferta, así como analizar la distribución de precios y puntajes para comprender la estructura general del mercado. También se evaluó si existen relaciones significativas entre las variables numéricas, particularmente entre precio y puntaje, con el fin de determinar si el costo del vino es un indicador confiable de su calidad.

Otra parte del análisis se centró en la relación calidad–precio, para lo cual se calculó la métrica QPR (Quality–Price Ratio) y se investigó qué vinos ofrecen un mayor valor relativo. También, se exploró el lenguaje utilizado por los críticos mediante técnicas de análisis de texto, con el objetivo de identificar los atributos sensoriales más mencionados y evaluar si el vocabulario varía según el puntaje del vino.


Las preguntas clave que guiaron este proceso incluyen:

- ¿Cómo se distribuyen los precios y puntajes en el dataset?
- ¿Qué países y variedades tienen mayor presencia y cómo se comportan en términos de calidad?
- ¿Existe relación entre el precio y el puntaje otorgado por los críticos?
- ¿Qué vinos presentan la mejor relación calidad–precio?
- ¿Qué atributos sensoriales destacan en las descripciones y cómo varían según la calidad del vino?

Estas preguntas permitieron orientar la selección de visualizaciones y estructurar el análisis que resulta útil tanto para productores como para comerciantes y consumidores.

Creación de visualizaciones efectivas

Distribución de la variable points



La variable points representa la puntuación otorgada a cada vino. Los valores válidos se encuentran entre 80 y 100 puntos. Durante la limpieza se detectaron valores superiores a 100, los cuales fueron reemplazados por NaN al tratarse de errores de carga.

Para comprender la distribución de esta variable se construyó un histograma con curva KDE, lo que permite observar tanto la frecuencia de los puntajes como la forma general de la distribución.

Los principales resultados fueron:

- **Mínimo:** {min_val}
- **Máximo:** {max_val}
- **Media:** {mean_val:.2f}


La distribución resultante es unimodal, con una fuerte concentración entre 85 y 95 puntos. Este gráfico permite identificar rápidamente la ausencia de vinos con puntajes bajos y confirma que el dataset está sesgado hacia vinos de calidad media-alta y alta, algo esperable en publicaciones especializadas.

Para los **productores**, la distribución funciona como un punto de referencia para evaluar su posición competitiva. Saber que la mayoría de los vinos se ubican en un rango alto les permite identificar el estándar mínimo esperado por los críticos y orientar mejoras en sus procesos productivos. Además, los puntajes elevados pueden utilizarse como herramienta de posicionamiento y comunicación, reforzando la percepción de calidad de la marca.

Para los **comerciantes**, la distribución es útil para la toma de decisiones de compra y selección de productos. La presencia de numerosos vinos con puntajes altos, incluso en rangos de precio accesibles, permite identificar oportunidades de venta con buena relación calidad–precio.

En conjunto, la distribución de *points* aporta información clave para comprender el nivel de calidad del mercado, orientar estrategias de producción y optimizar decisiones comerciales.

Distribución de la variable price



La variable price representa el precio en dólares de cada vino. Al analizarla, se observó que presenta una alta dispersión y valores extremadamente elevados, lo que genera una distribución fuertemente asimétrica hacia la derecha. Esto es habitual en datasets de vinos, donde existen muchos productos económicos y una minoría de vinos de lujo con precios muy altos.

Para visualizar correctamente la forma de la distribución, se generó un histograma con curva KDE, limitando el eje X al rango 0–200 USD, ya que el valor máximo supera ampliamente ese rango y distorsiona la escala del gráfico.

Las estadísticas principales fueron:

- **Mínimo:** {min_price}
- **Máximo:** {max_price}
- **Media:** {mean_price:.2f}

El gráfico muestra que, la mayoría de los vinos se concentran entre 10 y 40 USD, la distribución es altamente asimétrica, con una cola larga hacia precios elevados y existen

outliers significativos, que justifican el análisis posterior mediante boxplots y métodos de detección de valores atípicos

Esta visualización permite comprender que el mercado de vinos evaluado está dominado por productos de precio accesible o medio, mientras que los vinos premium representan una proporción pequeña pero influyente en la media.

Análisis de la variable country


La variable country indica el país de origen de cada vino. Es una de las variables categóricas más importantes del dataset, ya que permite analizar la distribución geográfica de la producción y evaluar qué países tienen mayor presencia en las reseñas.

Para comprender su estructura se realizó un análisis general de la variable sobre las siguientes métricas: datos válidos (cantidad de registros que contienen un país), datos nulos (cantidad de filas donde el país no está especificado), cantidad de países distintos (número total de países representados en el dataset), frecuencia por país (cuántas reseñas corresponden a cada país)

Este análisis permite identificar: qué países dominan el mercado dentro del dataset (Estados Unidos, Francia, Italia). Si existen países con muy pocas reseñas, lo cual puede afectar la representatividad. La presencia de valores faltantes, que deben considerarse en la etapa de imputación o limpieza.

La distribución de países es fundamental para contextualizar el análisis, ya que la oferta de vinos y las características de cada región influyen directamente en el precio, la variedad de uva y la calidad percibida.

Top 10 países con mayor cantidad de vinos



Luego de realizar un análisis general sobre la variable country, se construyó un gráfico de barras con los 10 países que poseen mayor cantidad de reseñas.

El resultado muestra una alta concentración en pocos países, destacándose: Estados Unidos, con una cantidad de vinos muy superior al resto. Francia e Italia, dos de los mayores productores mundiales, ocupando el segundo y tercer lugar. España, Portugal, Chile y Argentina, que también presentan una presencia significativa.

Este patrón refleja tanto la importancia de estos países en el mercado internacional del vino como un sesgo con una sobrerrepresentación de Estados Unidos.

El gráfico permite visualizar claramente: la desigualdad en la cantidad de vinos reseñados entre países, la existencia de un núcleo dominante de productores, y la necesidad de considerar este sesgo en análisis comparativos posteriores (por ejemplo, al evaluar precios o puntajes por país).

Este tipo de visualización es fundamental para contextualizar el análisis y comprender qué regiones tienen mayor peso dentro del conjunto de datos.

Análisis de la variable variety


Al igual que con la variable country se realiza un análisis previo general sobre la variable variety la cual indica la variedad de uva utilizada en cada vino. Es una de las variables categóricas más relevantes del dataset, ya que permite estudiar tendencias de producción, preferencias del mercado y posibles relaciones entre variedad, precio y puntaje.

Para comprender su estructura se calcularon las siguientes métricas: datos válidos (cantidad de registros donde la variedad está informada), datos nulos (cantidad de filas sin información de variedad), cantidad de variedades distintas (número total de tipos de uva presentes en el dataset), frecuencia por variedad (cuántas reseñas corresponden a cada tipo de uva).

Este análisis permite identificar las variedades más populares dentro del dataset, la diversidad del conjunto de datos, ya que suelen aparecer más de 500 variedades distintas, la presencia de valores faltantes, que deben considerarse en análisis posteriores.

La variable *variety* es fundamental para explorar patrones de calidad, precio y origen, ya que cada tipo de uva tiene características propias que influyen en el estilo y valor del vino.

Top 10 variedades con mayor cantidad de vinos



Para analizar la distribución de los tipos de uva presentes en el dataset, se construyó un gráfico de barras con las 10 variedades más frecuentes. Este análisis permite identificar cuáles son las uvas más representadas en las reseñas y, por lo tanto, cuáles tienen mayor presencia en el mercado evaluado.

Las variedades más destacadas fueron:

- Pinot Noir
- Chardonnay
- Cabernet Sauvignon
- Red Blend
- Bordeaux-style Red Blend

Estas variedades concentran una gran proporción del total de vinos, lo que refleja tanto su popularidad global como su relevancia en los mercados de Estados Unidos y Europa, principales regiones representadas en el dataset.

El gráfico permite observar, una alta concentración en pocas variedades, lo que indica que el dataset no está distribuido de manera uniforme, la presencia de variedades blancas y tintas dentro del Top 10, mostrando diversidad estilística, la importancia de considerar esta concentración en análisis posteriores, ya que variedades con muy pocos registros pueden generar resultados menos representativos.

Este tipo de visualización es fundamental para comprender la estructura del dataset y para contextualizar análisis posteriores sobre precio, puntaje y país de origen.

Análisis de la variable winery

La variable winery identifica la bodega responsable de cada vino. Es una variable


categoría clave, ya que permite analizar la concentración del mercado, la diversidad de productores y la presencia relativa de cada bodega dentro del dataset.

Para comprender su estructura se calcularon las siguientes métricas: datos válidos (cantidad de registros donde la bodega está informada), datos nulos (cantidad de filas sin información disponible), cantidad de bodegas distintas (número total de productores presentes en el dataset), frecuencia por bodega (cantidad de vinos asociados a cada productor).

Este análisis permite identificar: bodegas con mayor presencia en el dataset, la alta diversidad del conjunto de datos, ya que generalmente aparecen miles de bodegas distintas, muchas de ellas con muy pocos vinos reseñados, la existencia de valores faltantes o inconsistentes.

La variable *winery* es fundamental para estudiar patrones de producción, comparar estilos entre bodegas y analizar la relación entre origen, variedad, precio y puntaje.

Top 10 bodegas con mayor cantidad de vinos



Para analizar la presencia de productores dentro del dataset, se elaboró un gráfico de barras con las 10 bodegas que poseen mayor cantidad de vinos reseñados. Este análisis permite identificar qué productores tienen mayor visibilidad y volumen dentro del mercado evaluado.

Entre las bodegas más destacadas se encuentran:

- Wines & Winemakers
- Testarossa
- DFJ Vinhos
- Williams Selyem

- Georges Duboeuf

Estas bodegas concentran una cantidad significativamente mayor de vinos en comparación con el resto, lo que refleja: un alto nivel de producción, desigualdad en la distribución del número de vinos por bodega, donde unas pocas concentran gran parte del total, y la existencia de miles de bodegas con muy pocos vinos reseñados, lo que evidencia un mercado altamente fragmentado.

El gráfico permite visualizar de manera clara esta concentración y sirve como base para análisis posteriores, como comparar puntajes promedio por bodega o estudiar la relación entre volumen de producción y precio.

Promedios de puntaje y precio por país, bodega y variedad

Con el objetivo de identificar patrones de calidad y valor dentro del dataset, se calcularon los promedios de puntos y precios agrupados por tres variables clave: país de origen (country), bodega (winery), variedad de uva (variety).

Este análisis permite comparar regiones, productores y tipos de uva en términos de calidad percibida y posicionamiento económico.

1. Promedios por país

El cálculo del puntaje promedio por país permite identificar qué regiones presentan vinos mejor valorados por los críticos. Del mismo modo, el precio promedio por país muestra diferencias en el posicionamiento económico de cada mercado. Con este análisis podemos ver: países con puntajes promedio más altos, que suelen corresponder a regiones tradicionales o con fuerte reputación, países con precios promedio elevados, asociados a vinos premium o mercados de lujo.

2. Promedios por bodega


El análisis por bodega permite identificar productores que consistentemente obtienen: altos puntajes promedio, lo que refleja calidad sostenida, precios promedio elevados, lo que puede indicar prestigio, producción limitada o vinos de alta gama.

Este tipo de análisis es útil para detectar bodegas destacadas dentro del dataset.

3. Promedios por variedad

El cálculo de puntajes y precios promedio por variedad de uva permite observar: qué variedades tienden a recibir mejores evaluaciones, qué tipos de uva están asociados a vinos más costosos, diferencias entre variedades tintas, blancas y blends.

Este análisis es fundamental para comprender la relación entre estilo de vino, calidad percibida y precio.

Comparación entre puntaje y precio promedios por país

Para analizar la relación entre calidad percibida y posicionamiento económico de los vinos según su origen, se elaboraron dos gráficos comparativos:

- Top 10 países con mejor puntaje promedio
- Top 10 países con mayor precio promedio

Estos gráficos dejan ver si los países que producen vinos más caros son también los que obtienen mejores evaluaciones por parte de los críticos.

El ranking de puntaje promedio muestra que algunos países menos representados en cantidad de vinos pueden aparecer en los primeros lugares debido a:


- Producciones más selectas
- Vinos de alta calidad
- Menor variabilidad interna

El ranking de precio promedio revela diferencias importantes entre mercados:

- Algunos países presentan precios promedio muy elevados debido a vinos premium o de lujo.
- Otros países, aunque con buena calidad, mantienen precios más accesibles.

Este análisis permite identificar regiones con vinos de alto valor económico, independientemente del puntaje.

La comparación entre ambos rankings muestra que: un puntaje alto no siempre implica un precio alto, lo que indica que existen países con excelente relación calidad-precio, los países con precios más elevados no necesariamente obtienen los mejores puntajes, lo que sugiere que el valor económico está influido por factores externos como prestigio, marketing o rareza. Este análisis es útil tanto para consumidores como para comerciantes, ya que permite identificar mercados competitivos y oportunidades de compra.

Comparación entre puntaje y precio promedios por bodega

Para analizar el desempeño y posicionamiento económico de los productores dentro del dataset, se elaboraron dos gráficos comparativos:

- Top 10 bodegas con mejor puntaje promedio
- Top 10 bodegas con mayor precio promedio

Este análisis permite identificar bodegas destacadas tanto por calidad como por valor económico.

El ranking de puntaje promedio muestra bodegas que, aunque no necesariamente producen grandes volúmenes, obtienen evaluaciones consistentemente altas. Estas bodegas suelen caracterizarse por:

- Producciones más cuidadas
- Enfoque en vinos premium
- Estilos muy valorados por críticos especializados

Este indicador es útil para identificar productores con reputación sólida en términos de calidad.

El ranking de precio promedio revela bodegas cuyo posicionamiento económico es elevado. Esto puede deberse a:


- Producción limitada
- Vinos de alta gama
- Prestigio internacional
- Mercados exclusivos

No siempre coincide con el ranking de puntaje, lo que permite detectar bodegas con precios altos, pero puntajes moderados, o bodegas con excelente calidad a precios más accesibles.

La comparación entre ambos rankings muestra que: las bodegas más caras no siempre son las mejor puntuadas, lo que evidencia que el precio está influido por factores adicionales a la calidad. Que existen bodegas con excelente relación calidad-precio, que

aparecen en el ranking de puntaje, pero no en el de precio. Este análisis permite identificar productores destacados y comprender mejor la estructura del mercado representado en el dataset.

Comparación entre puntaje y precio promedios por variedad



Para analizar la relación entre calidad percibida y valor económico según el tipo de uva, se elaboraron dos gráficos comparativos:

- Top 10 variedades con mejor puntaje promedio
- Top 10 variedades con mayor precio promedio

Este análisis permite identificar variedades destacadas tanto por calidad como por posicionamiento económico.

El ranking de puntaje promedio muestra variedades que, aunque no siempre son las más comunes, reciben evaluaciones consistentemente altas. Estas variedades suelen estar asociadas a:

- Producciones más cuidadas

Este indicador permite identificar variedades que se destacan por su calidad intrínseca.

El ranking de precio promedio revela variedades asociadas a vinos premium o de lujo. En este caso, suelen aparecer:

- Variedades raras o poco producidas
- Uvas utilizadas en vinos de alta gama
- Estilos exclusivos o de producción limitada

Es habitual que algunas variedades extremadamente caras no aparezcan en el ranking de puntaje, ya que el precio puede estar influido por factores como rareza, prestigio o demanda del mercado.

La comparación entre ambos rankings muestra que: las variedades más caras no siempre son las mejor puntuadas, lo que evidencia que el precio no depende únicamente de la calidad. Existen variedades con excelente relación calidad-precio, que aparecen en

el ranking de puntaje, pero no en el de precio.

Este análisis es fundamental para comprender cómo se distribuyen la calidad y el valor económico dentro del mercado representado en el dataset

Detección de outliers en la variable price

Para analizar la presencia de valores atípicos en el precio de los vinos, se aplicó el método del Rango Intercuartílico (IQR). Previamente se filtraron los precios inválidos (≤ 0), ya que no representan valores reales.

Los resultados obtenidos fueron:

Q1 = 17 USD

Q3 = 42 USD

IQR = 25 USD


Límite superior = 79.5 USD

Límite inferior = -20.5 USD (descartado por no tener sentido práctico)

Dado que el límite inferior es negativo, solo se consideraron outliers superiores, es decir, vinos cuyo precio supera los 79.5 USD. Se identificaron 7641 outliers, lo cual es esperable debido a la presencia de vinos premium, de lujo o de producción limitada. Estos valores no representan errores, sino productos reales de alto valor económico. Por este motivo, los outliers no fueron eliminados, sino analizados como parte natural de la distribución del precio.

Este análisis permite comprender la fuerte asimetría de la variable *price* y la existencia de un segmento de vinos de gama alta dentro del dataset.

Boxplot de la variable price




Se construyó un boxplot para analizar la distribución del precio de los vinos. Para

evitar que los valores extremos distorsionaran la visualización, el eje X se acotó al rango 0–200 USD, lo cual permite observar con mayor claridad la estructura central de la variable.

El gráfico muestra que la mayoría de los vinos se concentran entre 10 y 40 USD, lo que indica un mercado dominado por productos de gama media, la mediana se ubica alrededor de los 25 USD, reflejando el precio típico del dataset. La distribución presenta una cola larga hacia la derecha, asociada a vinos premium o de lujo. Se observan numerosos outliers superiores, que corresponden a vinos cuyo precio supera ampliamente el rango habitual, pero que no representan errores sino productos reales de alto valor.


Este boxplot confirma la fuerte asimetría de la variable *price* y la presencia de un segmento de vinos de alta gama dentro del dataset.

Boxplot de la variable price sin outliers




Para poder analizar la distribución central del precio sin la influencia de valores extremos, se construyó un boxplot utilizando únicamente los vinos cuyo precio se encuentra por debajo del límite superior del IQR (79.5 USD).

El gráfico muestra una distribución mucho más clara y representativa del mercado general, la mayoría de los vinos se concentran entre 17 y 42 USD, lo que coincide con el rango intercuartílico calculado previamente. La mediana se mantiene alrededor de 25 USD, reflejando el precio típico del dataset. La eliminación de outliers permite visualizar la forma real de la distribución sin la distorsión generada por vinos premium o de lujo. Este boxplot es útil para comprender el comportamiento del precio en el segmento mayoritario del mercado.

Boxplot de outliers de la variable price

Para analizar el comportamiento del segmento premium del mercado (vinos con precios altos), se construyó un boxplot utilizando únicamente los vinos cuyo precio supera el límite superior del IQR (79.5 USD). Este gráfico permite observar la distribución de los valores extremos sin la influencia del resto del dataset.

En el gráfico podemos ver una amplia dispersión de precios dentro del segmento de vinos premium. Valores que alcanzan cifras superiores a los 3000 USD, correspondientes a vinos de lujo o exclusivos. La presencia de múltiples niveles de outliers, lo que indica que incluso dentro de los vinos caros existen diferencias significativas en el valor económico.

Boxplot de la variable points


Se realizó un boxplot para analizar la distribución del puntaje asignado a los vinos. Dado que el sistema de puntuación está acotado entre 80 y 100 puntos, la distribución

presenta una variabilidad reducida.

El gráfico muestra que la mayoría de los vinos se ubica entre 85 y 93 puntos. La mediana se encuentra aproximadamente entre 88 y 90 puntos, lo que refleja una tendencia general a otorgar calificaciones altas. La presencia de outliers es mínima, ya que el rango de puntuación es estrecho y no permite valores extremos.

Este comportamiento indica que la variable *points* es relativamente estable y no presenta valores anómalos significativos, lo cual facilita su análisis y comparación con otras variables como el precio.


Distribución de puntos por variedad (Top 10)



Para analizar cómo varía la calidad percibida entre las variedades de vino más representadas en el dataset, se seleccionaron las 10 variedades con mayor cantidad de registros y se realizó un boxplot comparativo utilizando la variable *points*.

Este gráfico permite observar diferencias en la distribución de puntajes entre las variedades más populares. Podemos ver que algunas variedades presentan medianas más altas, lo que indica una tendencia a recibir mejores evaluaciones por parte de los críticos. Otras variedades muestran una mayor dispersión, reflejando una calidad más heterogénea dentro de la misma categoría. La presencia de outliers es baja debido a que la escala de puntaje está acotada entre 80 y 100 puntos. La comparación visual facilita identificar qué variedades tienden a obtener puntajes más consistentes y cuáles presentan mayor variabilidad.

Este análisis es útil para comprender cómo se distribuye la calidad dentro de las variedades más comunes del mercado y permite detectar patrones relevantes para estudios posteriores, como la relación entre variedad, precio y puntaje.

Distribución de precios en escala logarítmica

Dado que la variable *price* presenta una distribución altamente asimétrica, con una gran cantidad de vinos económicos y un conjunto reducido de vinos premium con precios muy elevados, se construyó un histograma utilizando una escala logarítmica en el eje X.

El uso de esta transformación permite reducir el efecto de los valores extremos, visualizar la forma real de la distribución sin que los precios altos distorsionen el gráfico, identificar con claridad el rango donde se concentra la mayoría de los vinos, y observar la presencia de un segmento de vinos de alta gama que se extiende hacia valores mucho mayores.

La escala logarítmica resulta especialmente útil en variables monetarias con fuerte asimetría, ya que mejora la interpretación visual y facilita el análisis comparativo.

Segmentación de precios en tres grupos

Se realizó una segmentación en tres grupos utilizando el método de terciles. Esta técnica divide la distribución real del precio en tres partes iguales, asignando a cada vino una categoría según su posición relativa en el mercado: económico, medio o premium.

Luego de la segmentación, se calcularon la cantidad y el porcentaje de vinos en cada grupo, lo que permite evaluar la composición del dataset en términos de niveles de precio.

Conteo de vinos por segmento de precio

A partir de la segmentación del precio en tres grupos mediante terciles (Económico, Medio y Premium), se construyó un gráfico de barras para visualizar la

cantidad de vinos pertenecientes a cada categoría. El gráfico muestra que los tres segmentos presentan cantidades similares de registros, lo cual es esperable dado que la segmentación se realizó utilizando *qcut*, que divide la distribución en partes iguales. Esta distribución equilibrada permite realizar comparaciones consistentes entre segmentos, ya que cada uno representa aproximadamente un tercio del total del dataset.


Tabla de conteo y porcentaje por segmento de precio

Luego de segmentar la variable *price* en tres grupos mediante terciles (Económico, Medio y Premium), se construyó una tabla resumen que muestra la cantidad de vinos en cada segmento y el porcentaje que representan dentro del dataset.

La tabla evidencia que los tres segmentos presentan proporciones similares, lo cual es esperable dado que la segmentación se realizó utilizando *qcut*, que divide la distribución en partes iguales. Esta distribución equilibrada permite realizar comparaciones consistentes entre los distintos niveles de precio y constituye una base sólida para los análisis posteriores.

	Conteo	Porcentaje (%)
Economico	45884	38.16
Medio	34524	28.71
Premium	39823	33.12

Top 10 vinos con mejor relación calidad-precio (QPR)



La métrica QPR permite identificar vinos que tienen puntajes altos, pero precios

bajos, por lo tanto, ofrecen excelente relación calidad–precio.

Para evaluar qué vinos ofrecen la mejor relación entre calidad y precio, se calculó la métrica Quality–Price Ratio (QPR) definida como:

$$QPR = \frac{\text{points}}{\text{price}}$$


Esta métrica permite identificar vinos que obtienen puntajes elevados a un costo relativamente bajo. Luego de filtrar valores válidos (precio mayor a cero), se seleccionaron los 10 vinos con mayor QPR.

Los resultados muestran que los vinos con mejor relación calidad–precio no necesariamente pertenecen al segmento premium. Por el contrario, suelen ser vinos económicos que alcanzan puntajes altos, lo que los convierte en opciones especialmente atractivas para los comerciantes. Este análisis complementa la evaluación tradicional basada únicamente en el puntaje y permite identificar productos con un rendimiento sobresaliente por cada dólar invertido.

Este gráfico muestra los 10 vinos que ofrecen la mejor relación calidad–precio según la métrica QPR (puntos / precio). Lo que se observa es que los vinos del Top 10 tienen puntajes altos (generalmente entre 90 y 95), sus precios son muy bajos, lo que dispara el valor del QPR. La lista está dominada por vinos económicos con calificaciones altas.

Esto los convierte en opciones especialmente atractivas para comerciantes que pueden ofrecer a sus clientes alta calidad sin que deban realizar un gasto elevado. Este análisis permite identificar vinos con un gran desempeño en términos de valor percibido.

Relación entre precio y puntaje por segmento de precio



El análisis de la relación entre precio y puntaje tiene implicancias directas para la toma de decisiones estratégicas en producción, posicionamiento y comercialización.

En cuanto a los comerciantes, estos pueden identificar buenos vinos (con alto puntaje) a un precio económico, esto permite que dichos vinos se vendan más rápido o un margen mas grande, ya que al ser de buena calidad pueden venderse a un mayor precio. También permite identificar vinos caros con un bajo puntaje, para no hacer una inversión grande en productos que no suelen venderse rápido por su alto costo.

[illegible]

Para analizar el lenguaje utilizado por los críticos en las reseñas, se construyó una nube de palabras a partir de la columna *description*. Esta visualización permite identificar los términos más frecuentes y obtener una visión general de los atributos más mencionados en la evaluación de los vinos.

El word cloud revela la presencia recurrente de palabras asociadas a aromas, sabores, estructura y sensaciones en boca, tales como notas frutales, especiadas, acidez, taninos y final. Estos términos reflejan los aspectos que los catadores consideran más relevantes al describir un vino y permiten comprender qué características predominan en el conjunto de reseñas.

Esta representación resulta útil para captar de manera rápida los conceptos clave del lenguaje enológico presente en el dataset.


Análisis de frecuencia de palabras en las descripciones

Este procesamiento permite identificar las palabras más frecuentes en las descripciones de los vinos, se realizó un preprocesamiento del texto que incluyó la conversión a minúsculas, la eliminación de signos de puntuación y la remoción de stopwords tanto generales como específicas del dominio enológico.

Posteriormente, se calcularon las 20 palabras más frecuentes. Los resultados muestran al igual que en el Word cloud una fuerte presencia de términos asociados a aromas, sabores, estructura y sensaciones en boca, tales como referencias a taninos, acidez, dulzor, especias y características como “fresh”, “rich” o “balanced”. Estos términos reflejan los aspectos que los catadores consideran más relevantes al describir un vino y permiten comprender los atributos que predominan en el lenguaje enológico del dataset.


Este análisis complementa la nube de palabras y proporciona una visión cuantitativa de los conceptos más recurrentes en las descripciones.

Top 20 términos más frecuentes en las descripciones



El gráfico muestra de manera clara las 20 palabras más frecuentes en las descripciones de los vinos, después de limpiar el texto y eliminar stopwords generales y específicas del dominio enológico. Este análisis complementa la nube de palabras y aporta una visión cuantitativa sobre los conceptos más utilizados en las evaluaciones.

Comparación de términos frecuentes según el puntaje del vino




Para analizar diferencias en el lenguaje utilizado por los críticos, se separaron las descripciones en dos grupos: vinos con puntaje alto (≥ 90 puntos) y vinos con puntaje bajo (< 85 puntos). Luego se realizó un procesamiento de texto que incluyó limpieza, eliminación de stopwords y conteo de frecuencia de palabras.

Los resultados muestran que los vinos con puntajes elevados presentan un vocabulario asociado a complejidad y riqueza sensorial, con términos como “rich”, “complex”, “balanced” o “smooth”. En contraste, los vinos con puntajes bajos suelen

describirse con palabras que reflejan simplicidad, tales como “light”, “simple”, “thin” o “short”.

Esta comparación evidencia que el lenguaje enológico utilizado por los críticos varía significativamente según la calidad percibida del vino, y permite identificar patrones descriptivos asociados a cada rango de puntaje.

Mapa de calor de correlaciones



Para analizar las relaciones entre las variables numéricas del dataset, se construyó un mapa de calor que muestra los coeficientes de correlación entre ellas. Esta visualización permite identificar patrones generales y evaluar si existen asociaciones fuertes que puedan influir en el análisis.


El heatmap revela que la correlación entre precio y puntaje es baja, lo que indica que un vino más costoso no necesariamente obtiene una mejor calificación por parte de los críticos. Este resultado es consistente con lo observado en los gráficos de dispersión y refuerza la idea de que el precio no es un predictor directo de la calidad percibida.

Por otro lado, la métrica QPR presenta una correlación negativa con el precio, dado que se define como la relación entre puntos y costo. Esto confirma que los vinos económicos con buenos puntajes tienden a destacar en términos de relación calidad–precio.

En conjunto, el mapa de calor aporta una visión global de las relaciones entre variables y complementa los análisis previos, permitiendo una interpretación más completa del comportamiento del mercado de vinos.

Distribución de puntajes por variedad (Top 10)

Para realizar un análisis sobre cómo varía la calidad dentro de cada variedad de



uva, se construyó un violin plot utilizando las diez variedades con mayor cantidad de vinos en el dataset. Este tipo de visualización permite observar simultáneamente la distribución completa de los puntajes, la densidad de valores y los cuartiles internos.

El gráfico muestra que algunas variedades presentan una distribución más concentrada en puntajes altos, lo que indica una mayor consistencia en la calidad percibida por los críticos. Otras variedades exhiben una mayor dispersión, reflejando una oferta más heterogénea en términos de calidad. Esta visualización resulta especialmente útil para identificar variedades que tienden a destacarse de manera más uniforme y aquellas cuya calidad es más variable.

Interpretación y presentación

A partir de las visualizaciones realizadas, fue posible obtener una comprensión integral del comportamiento del mercado del vino representado en el dataset. Los gráficos permitieron analizar la distribución de precios y puntajes, identificar patrones de calidad según país, variedad y bodega, evaluar la relación entre precio y calificación, y explorar el lenguaje utilizado por los críticos en sus descripciones.

En primer lugar, la distribución de puntajes mostró que la mayoría de los vinos se concentra entre 85 y 95 puntos, lo que indica una tendencia general hacia calificaciones altas y una baja variabilidad en la evaluación de los críticos. Por otro lado, la distribución de precios evidenció una fuerte asimetría, con una gran cantidad de vinos económicos y un grupo reducido de vinos premium con valores significativamente más altos.

El análisis por país y variedad permitió identificar cuáles son las regiones y uvas más representadas, así como evaluar su consistencia en términos de calidad. Los boxplots y violin plots mostraron diferencias en la mediana y la dispersión de los puntajes, lo que resulta útil para productores que buscan posicionarse en mercados competitivos y para comerciantes que necesitan seleccionar vinos con calidad estable.

El gráfico de dispersión entre precio y puntaje, junto con el mapa de calor de correlaciones, deja ver que la relación entre ambas variables es débil. Esto significa que un vino más caro no necesariamente obtiene mejores calificaciones, lo cual es un hallazgo relevante para la toma de decisiones comerciales. La métrica QPR (Quality–Price Ratio) permite identificar vinos que ofrecen un rendimiento superior en términos de calidad relativa al precio.

Finalmente, el análisis de texto —incluyendo nubes de palabras, frecuencias y comparaciones entre vinos de alta y baja calidad— permitió comprender qué atributos sensoriales destacan los críticos y cómo varía el lenguaje según el puntaje. Los vinos mejor evaluados suelen asociarse a términos como “complex”, “balanced” o “rich”, mientras que los de menor puntaje se describen con palabras como “simple”, “light” o “thin”. Esta información es útil tanto para productores que buscan mejorar la comunicación de sus productos como para comerciantes que desean identificar perfiles sensoriales preferidos por el mercado.

En conjunto, las visualizaciones y análisis realizados permiten concluir que el precio no es un indicador directo de la calidad percibida, que existen diferencias significativas entre países y variedades en términos de consistencia y desempeño, y que el lenguaje enológico aporta información valiosa sobre la percepción de los críticos. Estos

resultados pueden ser utilizados por productores para orientar estrategias de posicionamiento y por comerciantes para optimizar la selección de vinos según calidad, precio y perfil sensorial.

Conclusión y utilidad para productores y comerciantes

Los resultados obtenidos no solo permiten comprender el comportamiento general del mercado del vino, sino que también ofrecen información accionable.

Para los productores, las visualizaciones permiten evaluar su posición competitiva en relación con otras regiones y variedades, identificar segmentos donde la calidad es más consistente y detectar oportunidades para diferenciarse. La evidencia de que el precio no garantiza un puntaje elevado refuerza la importancia de trabajar en atributos sensoriales, y estrategias de comunicación que destaquen la calidad real del producto. Además, el análisis del lenguaje utilizado por los críticos brinda información valiosa para ajustar descripciones, etiquetas y mensajes de marketing alineados con las características más valoradas por el mercado.

Para los comerciantes, el estudio facilita la selección de vinos con buena relación calidad-precio, especialmente al identificar productos económicos o de precio medio que obtienen puntajes altos y que pueden ofrecer una excelente rotación y aceptación del consumidor. La segmentación por país, variedad y rango de precio permite construir un portafolio equilibrado, minimizando el riesgo de stock inmovilizado y maximizando el atractivo comercial. Asimismo, la métrica QPR funciona como una herramienta práctica para detectar vinos competitivos que pueden destacarse sin pertenecer al segmento premium, lo que resulta especialmente útil en mercados sensibles al precio.

Luego del análisis se tiene una visión clara y fundamentada que puede ser utilizada para tomar decisiones estratégicas de producción, posicionamiento y comercialización, optimizando tanto la oferta como la comunicación de los vinos en el mercado.